Sprawozdanie z listy 1

Eksploracja danych

Piotr Katur, Wojciech Kowal

2026-04-02

Spis treści

1 Krótki opis zagadnienia **2**

2 Opis analiz **2**

3 Etap 1. Przygotowanie danych. Podstawowe informacje o danych **2**

3.1 Wczytanie zbioru danych i weryfikacja typów zmiennych 2

3.2 Struktura danych i czyszczenie 2

4 Etap 2. Analiza opisowa – wskaźniki sumaryczne i wykresy **3**

4.1 Podstawowe wskaźniki sumaryczne 3

4.2 Rozkład poszczególnych cech i interpretacja 4

4.3 Analiza zależności pomiędzy zmiennymi ciągłymi 6

5 Etap 3. Analiza opisowa z podziałem na grupy **6**

5.1 Wskaźniki opisowe i wykresy z podziałem na grupy (Churn) 6

5.2 Cechy najlepiej różnicujące klientów 8

6 Etap 4. Podsumowanie – wnioski z przeprowadzonej analizy **8**

6.1 Krótkie podsumowanie wyników z etapów 1–3 8

6.2 Profil typowego klienta firmy 9

6.3 Przyczyny odchodzenia (Churn) i co firma może z tym zrobić 9

1 Krótki opis zagadnienia

Celem poniższego sprawozdania jest eksploracja i analiza danych dotyczących klientów firmy telekomunikacyjnej (wykorzystano zbiór danych `WA_Fn-UseC_-Telco-Customer-Churn.csv`). W szczególności zbadane zostaną czynniki wpływające na rezygnację klientów z usług (zjawisko *Churn*).

2 Opis analiz

Analiza została przeprowadzona w środowisku R i podzielono ją na cztery główne etapy:

1. Przygotowanie i oczyszczenie zbioru danych.
2. Analiza opisowa poszczególnych zmiennych (wskaźniki sumaryczne i wizualizacje).
3. Analiza porównawcza z podziałem na grupy (lojalni klienci vs. klienci odchodzący).
4. Podsumowanie i wyciągnięcie wniosków biznesowych.

Do wykonania wizualizacji oraz odpowiedniego formatowania wykresów wykorzystano biblioteki `ggplot2` oraz `patchwork`.

3 Etap 1. Przygotowanie danych. Podstawowe informacje o danych

3.1 Wczytanie zbioru danych i weryfikacja typów zmiennych

```
dane <- read.csv(file="WA_Fn-UseC_-Telco-Customer-Churn.csv", stringsAsFactors = TRUE)
```

3.2 Struktura danych i czyszczenie

- **Jaki jest rozmiar danych?** Zbiór danych składa się z **7043 obserwacji** oraz **21 cech**.
- **Jakie są typy poszczególnych cech?** Większość cech w zbiorze to zmienne jakościowe (typ `factor`). Początkowo zidentyfikowano jedynie cztery zmienne wczytane jako ilościowe (liczbowe/numeryczne): `SeniorCitizen`, `tenure`, `MonthlyCharges` oraz `TotalCharges`.
- **Czy wszystkie cechy będą przydatne w analizie? (Identyfikatory)** Nie wszystkie. Pierwsza kolumna w zbiorze to `customerID`, która identyfikuje każdego klienta. Pełni ona rolę klucza głównego i nie niesie żadnych użytecznych informacji (nie ma wpływu na zachowanie klienta). W związku z tym została usunięta ze zbioru.

```r
# Usunięcie cechy pełniącej rolę identyfikatora
dane$customerID <- NULL
```

- **Czy w danych występują brakujące obserwacje i jak są kodowane?**

Tak, w danych znalazły się braki, czyli wartości `NA`. Występują one wyłącznie w jednej kolumnie: `TotalCharges` (Całkowite opłaty) i dotyczą 11 obserwacji. Po sprawdzeniu tych rekordów okazało się, że są to nowi klienci, których staż w firmie (`tenure`) wynosi równe 0 miesięcy. Skoro nie zdążyli oni jeszcze opłacić żadnego rachunku, logicznym jest zastąpienie `NA` wartością `0`.

```r
# Zastąpienie wartości NA zerami dla najnowszych klientów
dane$TotalCharges[is.na(dane$TotalCharges)] <- 0
```

- **Czy w danych występują nietypowe wartości?** Występował jeden problem ze strukturą: zmienna `SeniorCitizen` została wczytana jako liczbowa (przyjmując wartości 0 i 1). W istocie określa ona status seniora i jest cechą jakościową. W celu poprawy, zmieniono jej typ na `factor` i przypisano etykiety ("No", "Yes").

```r
# Zamiana SeniorCitizen na factor i nadanie etykiet
dane$SeniorCitizen <- as.factor(dane$SeniorCitizen)
levels(dane$SeniorCitizen) <- c("No", "Yes")
```

4 Etap 2. Analiza opisowa – wskaźniki sumaryczne i wykresy

4.1 Podstawowe wskaźniki sumaryczne

- **tenure (staż klienta):** Klienci pozostają w firmie średnio 32.37 miesiąca, jednak mediana wynosi 29 miesięcy.
- **MonthlyCharges (opłaty miesięczne):** Średnia opłata to około 64.76, podczas gdy mediana wynosi 70.35.
- **TotalCharges (całkowite opłaty):** Średnia to około 2279.7. Różnica między medianą (1394.5) a średnią wskazuje na asymetrię rozkładu.

4.2 Rozkład poszczególnych cech i interpretacja

4.2.1 Zmienne ilościowe

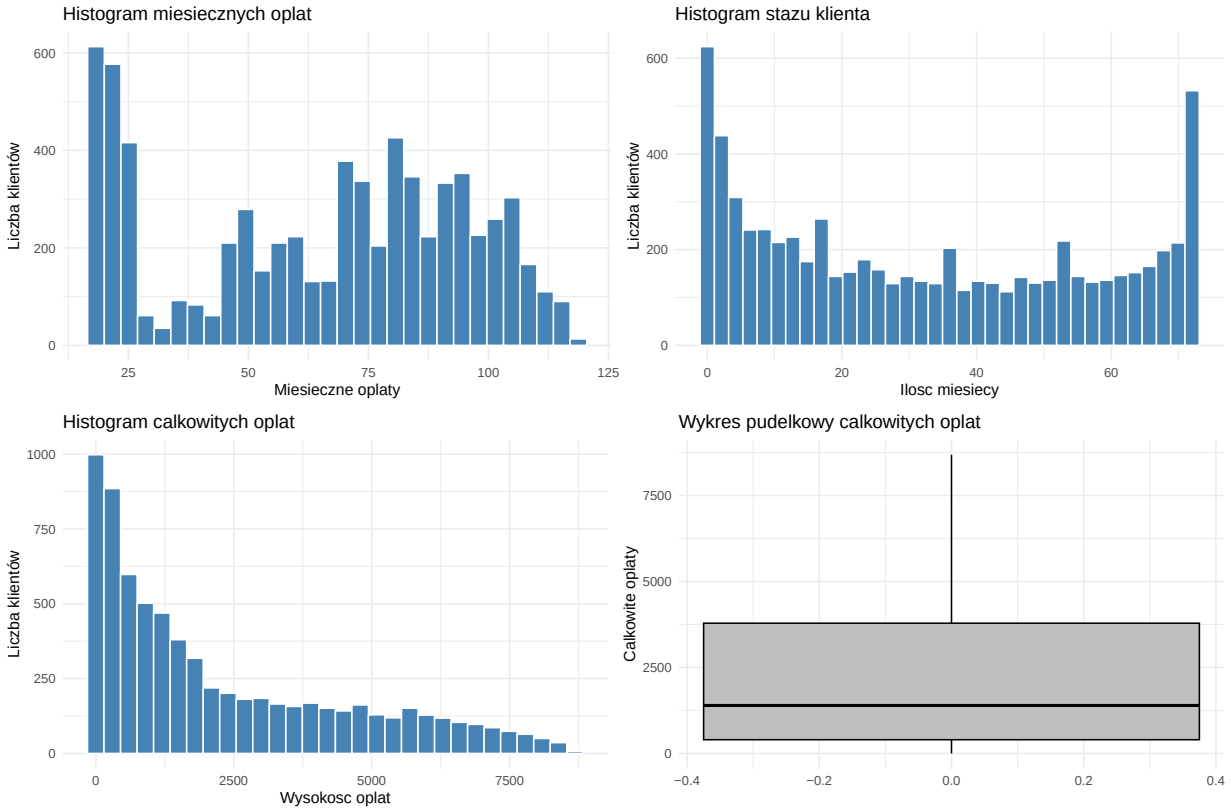

Rysunek 1: Zestawienie rozkładów dla zmiennych ilościowych.

Interpretacja rezultatów dla zmiennych ilościowych:

- **Jaki jest zakres możliwych wartości?** Zmienna `tenure` przyjmuje wartości z przedziału [0, 72] miesięcy. Zmienna `MonthlyCharges` waha się w przedziale [18.25, 118.75], natomiast `TotalCharges` przyjmuje wartości od 0 do 8684.8.
- **Czy wszystkie zmienne mają rozkład symetryczny?**
- **Które cechy charakteryzują się największą zmiennością?**

4.2.2 Zmienne jakościowe

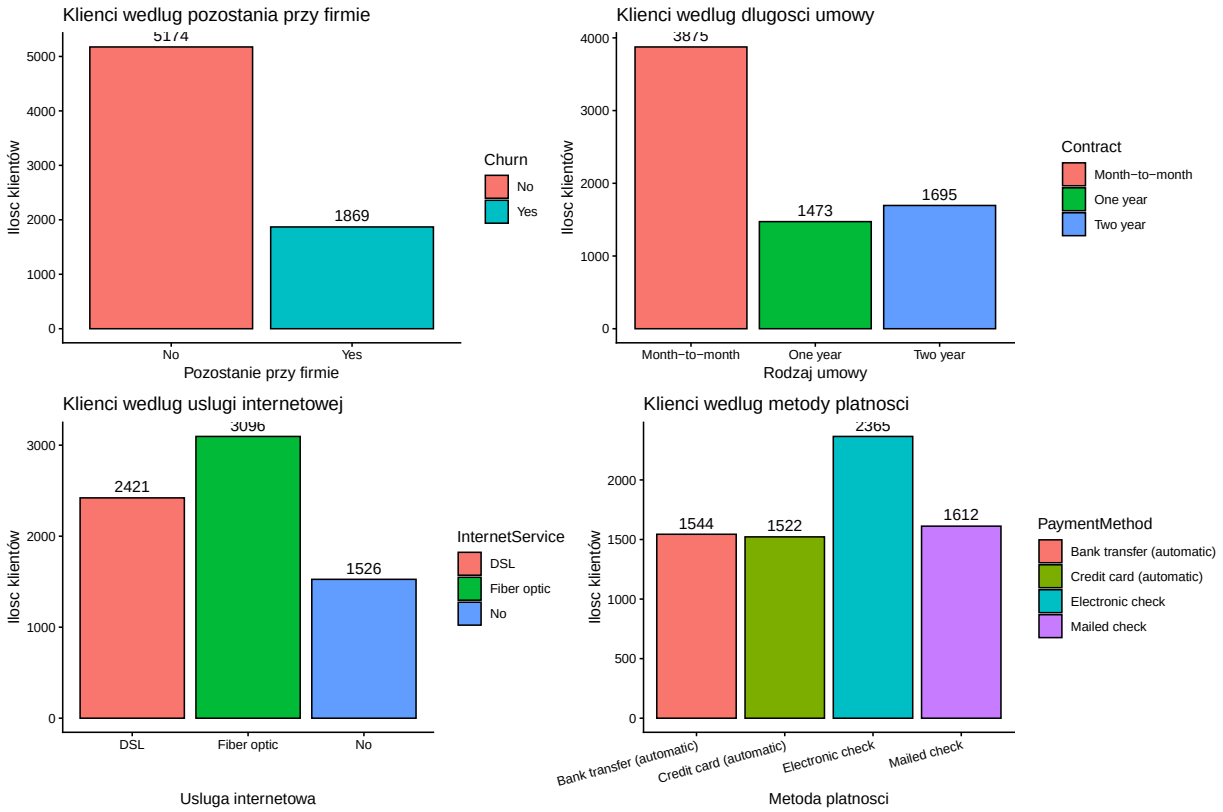

Rysunek 2: Zestawienie rozkładów dla kluczowych zmiennych jakościowych.

Interpretacja rezultatów dla zmiennych jakościowych:

- **Jaki jest zakres możliwych wartości?** Zmienne kategoryczne przyjmują zazwyczaj 2 wartości (np. "Yes"/"No" dla Churn lub usług dodatkowych) lub od 3 do 4 wartości w przypadku cech bardziej złożonych (np. 3 rodzaje dla `Contract` i `InternetService`, 4 dla `PaymentMethod`).
- **Co można powiedzieć o częstości przyjmowania poszczególnych kategorii?** Większość klientów (5174, co stanowi ~73%) pozostaje w firmie, a rezygnuje około 27% (1869). W przypadku rodzaju umów (`Contract`), najczęstszą formą jest umowa odnawiana co miesiąc ("Month-to-month"). Z wykresu usług internetowych wynika, że najpopularniejszym łączem jest światłowód (Fiber optic), przeważa on nad DSL. Wśród metod płatności dominuje "Electronic check".

4.3 Analiza zależności pomiędzy zmiennymi ciągłymi

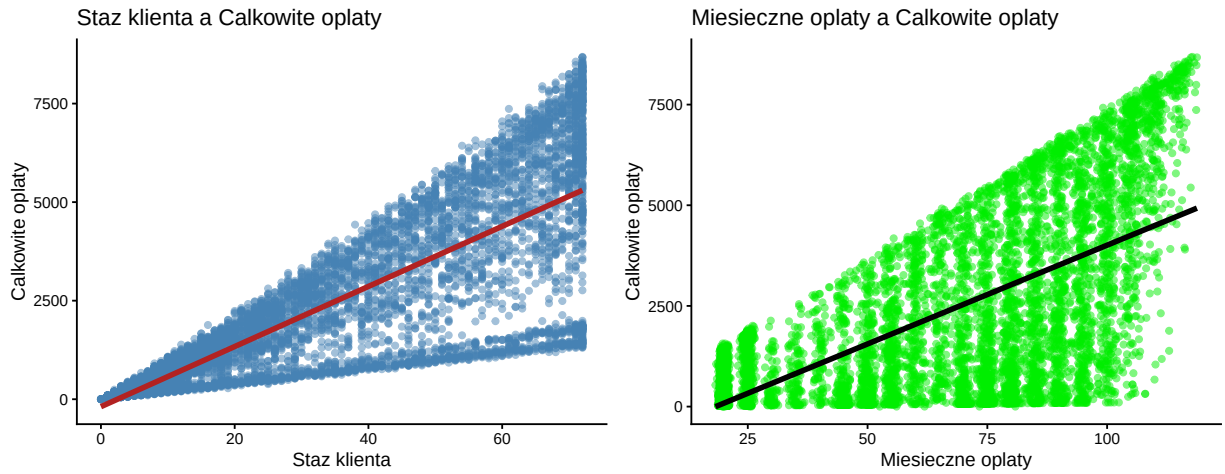

Rysunek 3: Wykresy rozrzutu dla zmiennych ciągłych wraz z dopasowaną prostą regresji.

Interpretacja zależności: Na pierwszym wykresie widać wyraźną zależność liniową między stażem klienta a całkowitymi opłatami – im dłużej klient korzysta z usług, tym wyższa jest suma opłaconych przez niego rachunków. Podobnie, wyższe opłaty miesięczne korelują z szybszym przyrostem całkowitych opłat.

5 Etap 3. Analiza opisowa z podziałem na grupy

5.1 Wskaźniki opisowe i wykresy z podziałem na grupy (Churn)

W dalszej analizie, zbiór danych podzielono na dwie podgrupy:

- **Grupa 1 (Churn == 'Yes'):** Klienci, którzy zrezygnowali z usług (odeszli).
- **Grupa 2 (Churn == 'No'):** Klienci kontynuujący współpracę.

5.1.1 Zmienne ilościowe - wykresy pudełkowe

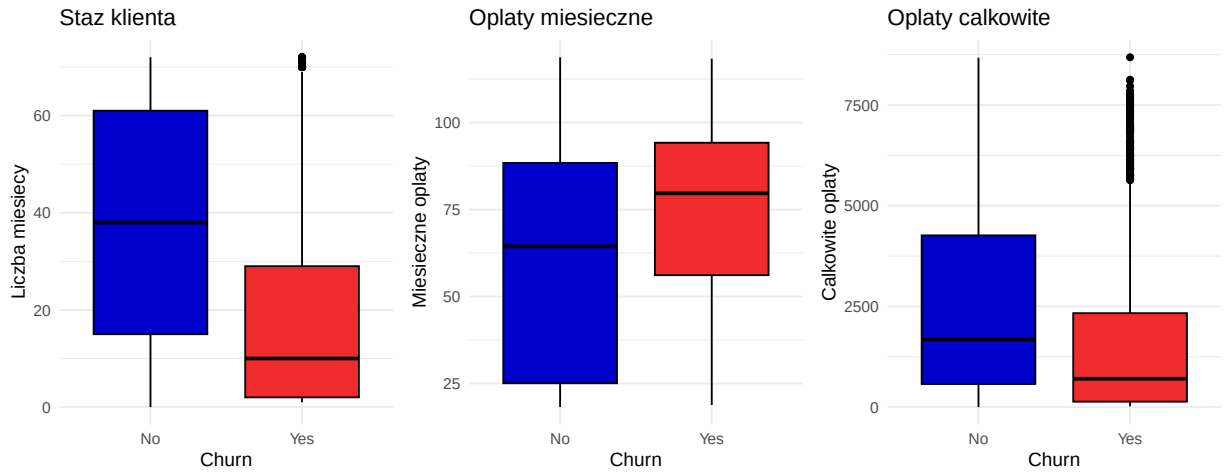

Rysunek 4: Wykresy pudełkowe zmiennych ilościowych w podziale na grupy (Churn).

5.1.2 Zmienne jakościowe - kluczowe wykresy kolumnowe

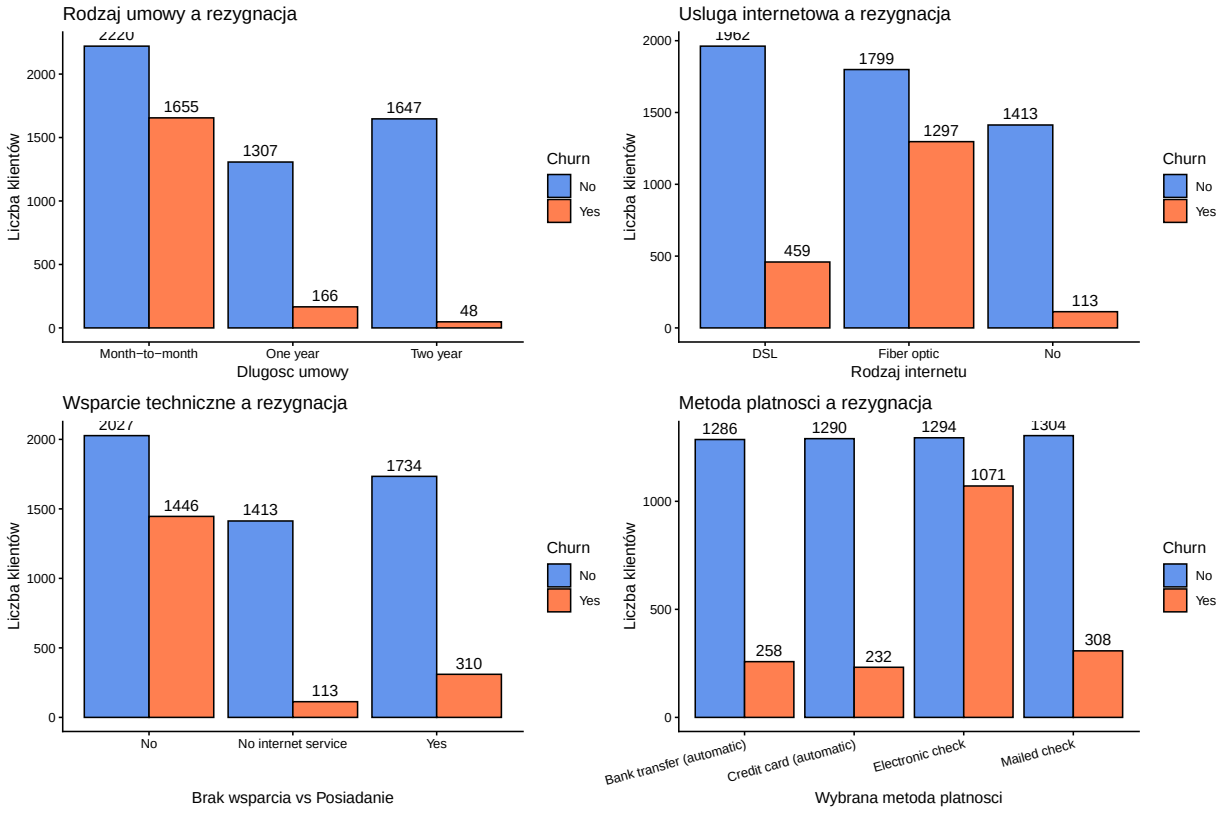

Rysunek 5: Zestawienie wybranych zmiennych jakościowych w podziale na Churn.

5.2 Cechy najlepiej różnicujące klientów

1. Zmienne ilościowe:

- **Staż klienta (`tenure`):** Klienci rezygnujący (Churn = "Yes") mają bardzo mocno skupiony rozkład przy małych wartościach (mediana to zaledwie kilka miesięcy), co oznacza, że rezygnują bardzo szybko po podpisaniu umowy. Klienci lojalni to w dużej mierze osoby o długim stażu (mediana to kilkadziesiąt miesięcy).
- **Miesięczne opłaty (`MonthlyCharges`):** Klienci płacący więcej miesięcznie (mediana rzędu blisko 80) częściej rezygnują z usług w porównaniu do grupy pozostającej, gdzie rozkład opłat jest szerszy, a mediana niższa (ok. 65).

2. Zmienne jakościowe:

- **Rodzaj umowy (`Contract`):** Ogromna większość klientów, którzy zrezygnowali, posiadała umowę odnawianą co miesiąc ("Month-to-month"). Odsetek rezygnacji wśród klientów z umowami na rok lub dwa lata ("One year", "Two year") jest bardzo mały.
- **Typ internetu (`InternetService`):** Klienci posiadający światłowód ("Fiber optic") decydują się na odejście częściej niż użytkownicy łącza "DSL" lub osoby w ogóle niekorzystające z internetu.
- **Usługi wsparcia i bezpieczeństwa (`TechSupport`, `OnlineSecurity`):** Z wykresów wynika, że brak dodatkowego wsparcia technicznego jest powiązany z wyższym wskaźnikiem rezygnacji.
- **Metoda płatności (`PaymentMethod`):** Klienci opłacający rachunki za pomocą elektronicznego czeku ("Electronic check") rezygnują drastycznie częściej niż osoby korzystające z innych metod, np. kart kredytowych czy przelewów bankowych.

6 Etap 4. Podsumowanie – wnioski z przeprowadzonej analizy

6.1 Krótkie podsumowanie wyników z etapów 1–3

W trakcie analizy przeszliśmy przez trzy główne kroki:

1. **Etap 1 (Przygotowanie danych):** Zbiór danych był całkiem uporządkowany. Wymagał jedynie drobnych poprawek, takich jak usunięcie niepotrzebnego ID klienta oraz wstawienie zer w opłatach u zupełnie nowych klientów.
2. **Etap 2 (Analiza opisowa):** Wykresy pokazały nam ogólny obraz sytuacji. Zauważyliśmy m.in., że większość klientów (około 73%) zostaje w firmie, a 27% decyduje się na odejście.
3. **Etap 3 (Analiza opisowa z podziałem na grupy):** Dzieląc klientów na tych, którzy odeszli i tych, którzy zostali, odkryliśmy, że rezygnacja z usług nie jest przypadkowa. Bardzo mocno zależy ona od takich rzeczy jak rodzaj umowy czy staż klienta.

6.2 Profil typowego klienta firmy

Na podstawie danych dowiedzieliśmy następujących faktór o klientach:

- **Kim są?** Klienci dzielą się mniej więcej po równo na kobiety i mężczyzn. Większość z nich nie ma nikogo na utrzymaniu i nie zalicza się do grupy seniorów.
- **Czego używają?** Prawie wszyscy mają telefon, a w przypadku internetu najchętniej wybierają światłowód. Dodatkowe usługi, jak telewizja czy filmy na żądanie, interesują około połowę z nich.
- **Jakie mają umowy?** Klienci bardzo cenią sobie elastyczność – zdecydowanie najczęściej wybierają umowę odnawianą z miesiąca na miesiąc i płacą za pomocą elektronicznego czeku.

6.3 Przyczyny odchodzenia (Churn) i co firma może z tym zrobić

6.3.1 Dlaczego klienci odchodzą?

Analiza wykazała, że klienci, którzy rezygnują z usług firmy, mają wspólne cechy:

1. **Odchodzą bardzo szybko:** Najwięcej rezygnacji pojawia się w pierwszych miesiącach po podpisaniu umowy.
2. **Mają krótkie umowy:** Odchodzą głównie osoby z umowami "z miesiąca na miesiąc", ponieważ mogą to zrobić w każdej chwili bez konsekwencji.
3. **Mają światłowód:** O dziwo, klienci korzystający ze światłowodu rezygnują częściej niż reszta. Może to oznaczać, że usługa ta jest za droga albo sprawia problemy techniczne.
4. **Nie mają wsparcia technicznego:** Osoby, które nie wykupiły dodatkowego wsparcia technicznego, częściej rezygnują z usług.

6.3.2 Co firma powinna zrobić?

Aby zatrzymać klientów, firma mogłaby wprowadzić kilka zmian:

1. **Zachęcać do dłuższych umów:** Skoro umowy miesięczne to główny powód ucieczek, warto kusić klientów zniżkami za podpisanie umowy na rok lub dwa lata.
2. **Zaopiekować się nowymi klientami:** Skoro klienci odchodzą na samym początku, firma powinna w pierwszych miesiącach częściej sprawdzać, czy wszystko u nich działa i czy są zadowoleni.
3. **Sprawdzić światłowody:** Należy sprawdzić, dlaczego ta usługa traci klientów – być może trzeba poprawić jej jakość lub obniżyć cenę.