Sprawozdanie z listy 1

Eksploracja danych

Piotr Katur, Wojciech Kowal

2026-04-03

Spis treści

1 Krótki opis zagadnienia **2**

2 Opis analiz **2**

3 Etap 1. Przygotowanie danych. Podstawowe informacje o danych **2**

3.1 Wczytanie zbioru danych i weryfikacja typów zmiennych 2

3.2 Struktura danych i czyszczenie 2

4 Etap 2. Analiza opisowa – wskaźniki sumaryczne i wykresy **3**

4.1 Podstawowe wskaźniki sumaryczne 3

4.2 Rozkład poszczególnych cech i interpretacja 4

4.3 Analiza zależności pomiędzy zmiennymi ciągłymi 6

5 Etap 3. Analiza opisowa z podziałem na grupy **6**

5.1 Wskaźniki opisowe i wykresy z podziałem na grupy (Churn) 6

5.2 Cechy najlepiej różnicujące klientów 8

6 Etap 4. Podsumowanie – wnioski z przeprowadzonej analizy **8**

6.1 Krótkie podsumowanie wyników z etapów 1–3 8

6.2 Profil typowego klienta firmy 9

6.3 Przyczyny odchodzenia (Churn) i co firma może z tym zrobić 9

1 Krótki opis zagadnienia

Celem poniższego sprawozdania jest eksploracja i analiza danych dotyczących klientów firmy telekomunikacyjnej (wykorzystano zbiór danych `WA_Fn-UseC_-Telco-Customer-Churn.csv`). W szczególności zbadane zostaną czynniki wpływające na rezygnację klientów z usług (zjawisko *Churn*).

2 Opis analiz

Analiza została przeprowadzona w środowisku R i podzielono ją na cztery główne etapy:

1. Przygotowanie i oczyszczenie zbioru danych.
2. Analiza opisowa poszczególnych zmiennych (wskaźniki sumaryczne i wizualizacje).
3. Analiza porównawcza z podziałem na grupy (lojalni klienci vs. klienci odchodzący).
4. Podsumowanie i wyciągnięcie wniosków biznesowych.

Do wykonania wizualizacji oraz odpowiedniego formatowania wykresów wykorzystano biblioteki `ggplot2` oraz `patchwork`.

3 Etap 1. Przygotowanie danych. Podstawowe informacje o danych

3.1 Wczytanie zbioru danych i weryfikacja typów zmiennych

```
dane <- read.csv(file="WA_Fn-UseC_-Telco-Customer-Churn.csv", stringsAsFactors = TRUE)
```

3.2 Struktura danych i czyszczenie

- **Jaki jest rozmiar danych?** Zbiór danych składa się z **7043 obserwacji** oraz **21 cech**.
- **Jakie są typy poszczególnych cech?** Większość cech w zbiorze to zmienne jakościowe (typ `factor`). Początkowo zidentyfikowano jedynie cztery zmienne wczytane jako ilościowe (liczbowe/numeryczne): `SeniorCitizen`, `tenure`, `MonthlyCharges` oraz `TotalCharges`.
- **Czy wszystkie cechy będą przydatne w analizie? (Identyfikatory)** Nie wszystkie. Pierwsza kolumna w zbiorze to `customerID`, która identyfikuje każdego klienta. Pełni ona rolę klucza głównego i nie niesie żadnych użytecznych informacji (nie ma wpływu na zachowanie klienta). W związku z tym została usunięta ze zbioru.

```r
# Usunięcie cechy pełniącej rolę identyfikatora
dane$customerID <- NULL
```

- **Czy w danych występują brakujące obserwacje i jak są kodowane?**

Tak, w danych znalazły się braki, czyli wartości `NA`. Występują one wyłącznie w jednej kolumnie: `TotalCharges` (Całkowite opłaty) i dotyczą 11 obserwacji. Po sprawdzeniu tych rekordów okazało się, że są to nowi klienci, których staż w firmie (`tenure`) wynosi równe 0 miesięcy. Skoro nie zdążyli oni jeszcze opłacić żadnego rachunku, logicznym jest zastąpienie `NA` wartością `0`.

```r
# Zastąpienie wartości NA zerami dla najnowszych klientów
dane$TotalCharges[is.na(dane$TotalCharges)] <- 0
```

- **Czy w danych występują nietypowe wartości?** Występował jeden problem ze strukturą: zmienna `SeniorCitizen` została wczytana jako liczbowa (przyjmując wartości 0 i 1). W istocie określa ona status seniora i jest cechą jakościową. W celu poprawy, zmieniono jej typ na `factor` i przypisano etykiety ("No", "Yes").

```r
# Zamiana SeniorCitizen na factor i nadanie etykiet
dane$SeniorCitizen <- as.factor(dane$SeniorCitizen)
levels(dane$SeniorCitizen) <- c("No", "Yes")
```

4 Etap 2. Analiza opisowa – wskaźniki sumaryczne i wykresy

4.1 Podstawowe wskaźniki sumaryczne

Tabela 1: Podstawowe wskaźniki sumaryczne dla zmiennych ilościowych

Zmienna	Minimum	Mediana	Średnia	Maksimum	Odch. std.	IQR
Staż (tenure)	0.00	29.00	32.37	72.00	24.56	46.00
Miesięczne (MonthlyCharges)	18.25	70.35	64.76	118.75	30.09	54.35
Całkowite (TotalCharges)	0.00	1394.55	2279.73	8684.80	2266.79	3388.05

- **Tenure (staż klienta):** Klienci pozostają w firmie średnio 32.37 miesiąca, jednak mediana wynosi 29 miesięcy.

- **MonthlyCharges (opłaty miesięczne):** Średnia opłata to około 64.76, podczas gdy mediana wynosi 70.35.
- **TotalCharges (całkowite opłaty):** Średnia to około 2279.7. Różnica między medianą (1394.5) a średnią wskazuje na asymetrię rozkładu.

4.2 Rozkład poszczególnych cech i interpretacja

4.2.1 Zmienne ilościowe

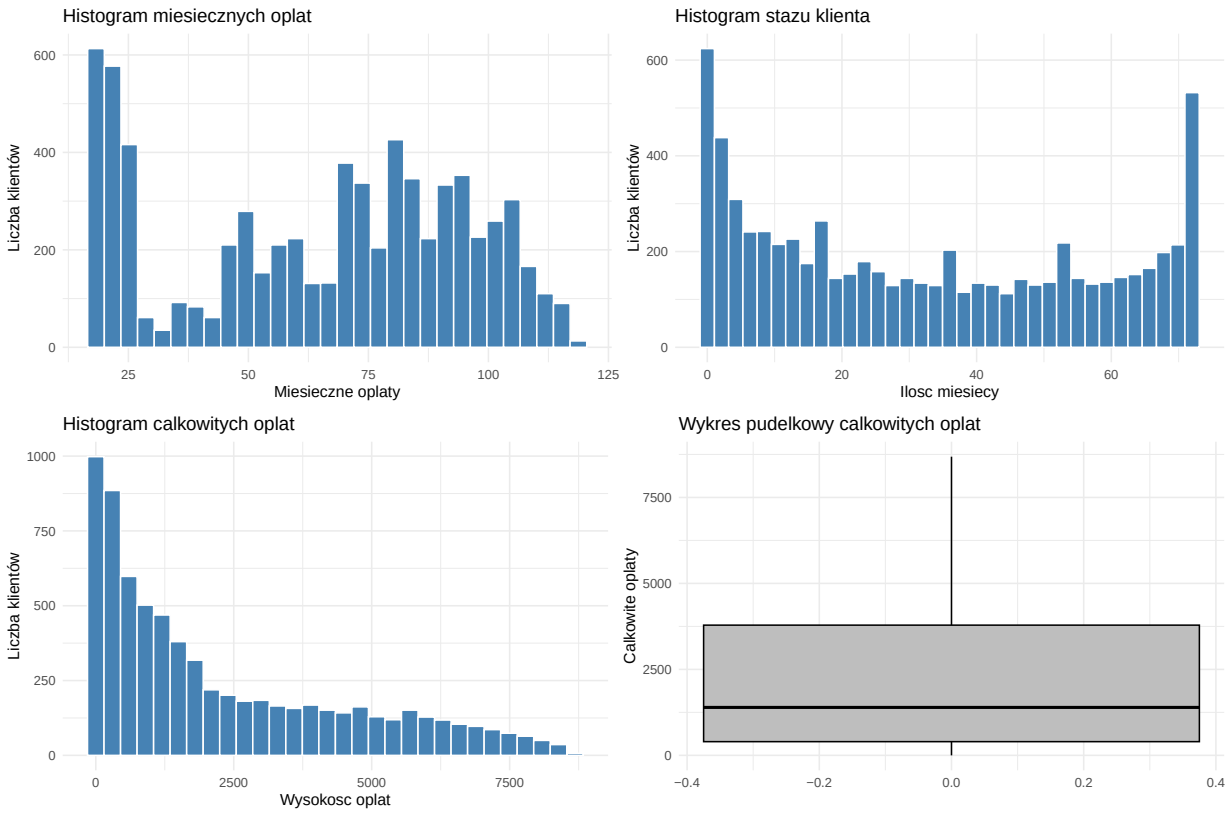

Rysunek 1: Zestawienie rozkładów dla zmiennych ilościowych.

Interpretacja rezultatów dla zmiennych ilościowych:

- **Jaki jest zakres możliwych wartości?** Zmienna `tenure` przyjmuje wartości z przedziału [0, 72] miesięcy. Zmienna `MonthlyCharges` waha się w przedziale [18.25, 118.75], natomiast `TotalCharges` przyjmuje wartości od 0 do 8684.8.
- **Czy wszystkie zmienne mają rozkład symetryczny?** Żadna z analizowanych zmiennych nie posiada rozkładu symetrycznego.

- Rozkład całkowitych opłat (`TotalCharges`) jest prawoskośny – histogram pokazuje, że zdecydowana większość klientów wygenerowała mniejsze łączne kwoty, a bardzo wysokie sumy należą są rzadkością.
- Na rozkładzie stażu klienta (`tenure`) widać, że w firmie dominują dwie skrajne grupy: klienci nowi (najwyższy słupek w okolicach 0 miesięcy) oraz bardzo lojalni (prawy skraj wykresu, ok. 70-72 miesiące).
- Rozkład opłat miesięcznych (`MonthlyCharges`) również jest asymetryczny, ze szczytem dla najniższych opłat (w okolicach wartości 20).

- **Które cechy charakteryzują się największą zmiennością?** Największą zmiennością charakteryzuje się zmienna `TotalCharges` (całkowite opłaty). Widać to na wykresie pudełkowym w prawym dolnym rogu – samo pudełko (reprezentujące środkowe 50% obserwacji) jest dość wysokie. Takie zróżnicowanie jest jednak naturalne, ponieważ opłaty rosną wraz ze stażem klienta.

4.2.2 Zmienne jakościowe

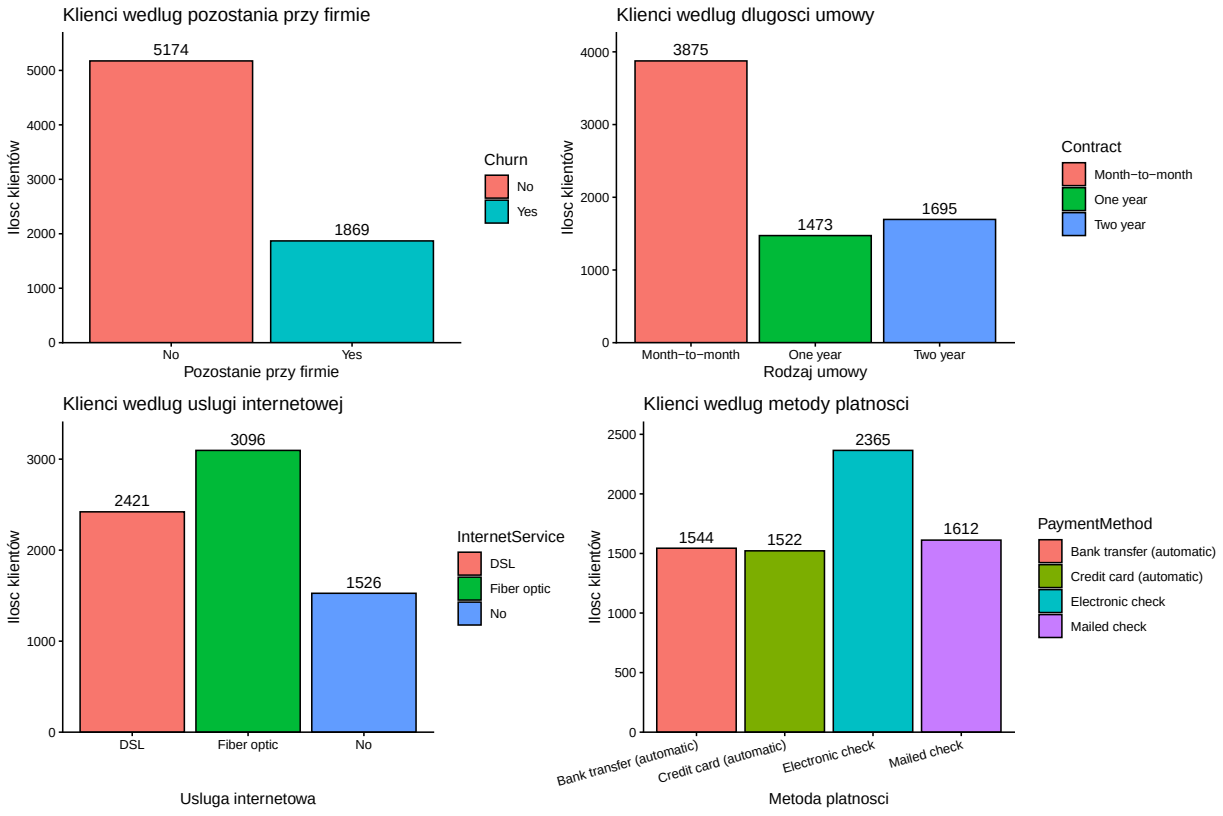

Rysunek 2: Zestawienie rozkładów dla kluczowych zmiennych jakościowych.

Interpretacja rezultatów dla zmiennych jakościowych:

- **Jaki jest zakres możliwych wartości?** Zmienne kategoryczne przyjmują zazwyczaj 2 wartości (np. "Yes"/"No" dla Churn lub usług dodatkowych) lub od 3 do 4 wartości w przypadku cech bardziej złożonych (np. 3 rodzaje dla `Contract` i `InternetService`, 4 dla `PaymentMethod`).
- **Co można powiedzieć o częstości przyjmowania poszczególnych kategorii?** Większość klientów (5174, co stanowi ~73%) pozostaje w firmie, a rezygnuje około 27% (1869). W przypadku rodzaju umów (`Contract`), najczęstszą formą jest umowa odnawiana co miesiąc ("Month-to-month"). Z wykresu usług internetowych wynika, że najpopularniejszym łączem jest światłowód (Fiber optic), przeważa on nad DSL. Wśród metod płatności dominuje "Electronic check".

4.3 Analiza zależności pomiędzy zmiennymi ciągłymi

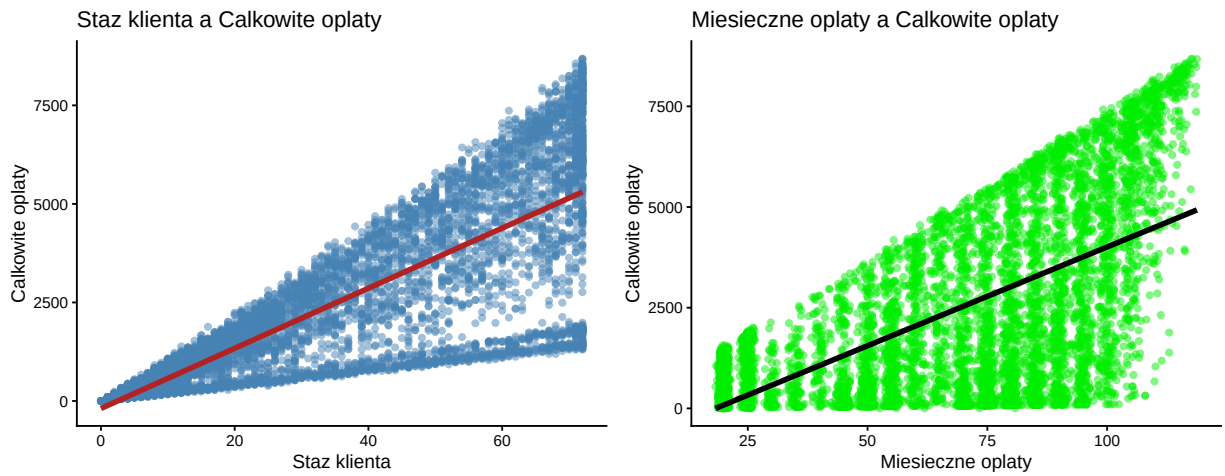

Rysunek 3: Wykresy rozrzutu dla zmiennych ciągłych wraz z dopasowaną prostą regresji.

Interpretacja zależności: Na pierwszym wykresie widać wyraźną zależność liniową między stażem klienta a całkowitymi opłatami – im dłużej klient korzysta z usług, tym wyższa jest suma opłaconych przez niego rachunków. Podobnie, wyższe opłaty miesięczne korelują z szybszym przyrostem całkowitych opłat.

5 Etap 3. Analiza opisowa z podziałem na grupy

5.1 Wskaźniki opisowe i wykresy z podziałem na grupy (Churn)

W dalszej analizie, zbiór danych podzielono na dwie podgrupy:

- **Grupa 1 (Churn == 'Yes'):** Klienci, którzy zrezygnowali z usług (odeszli).
- **Grupa 2 (Churn == 'No'):** Klienci kontynuujący współpracę.

5.1.1 Zmienne ilościowe - wykresy pudełkowe

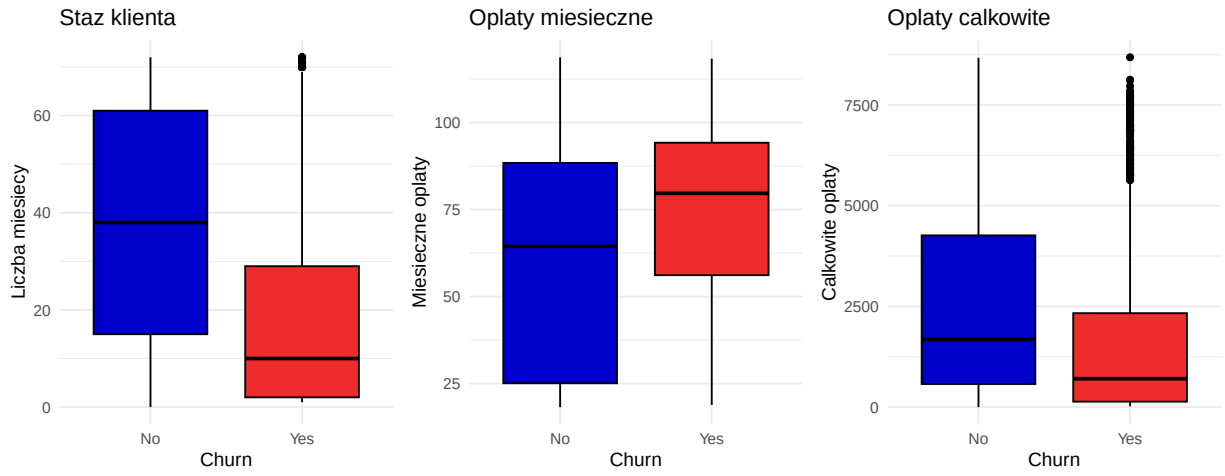

Rysunek 4: Wykresy pudełkowe zmiennych ilościowych w podziale na grupy (Churn).

5.1.2 Zmienne jakościowe - kluczowe wykresy kolumnowe

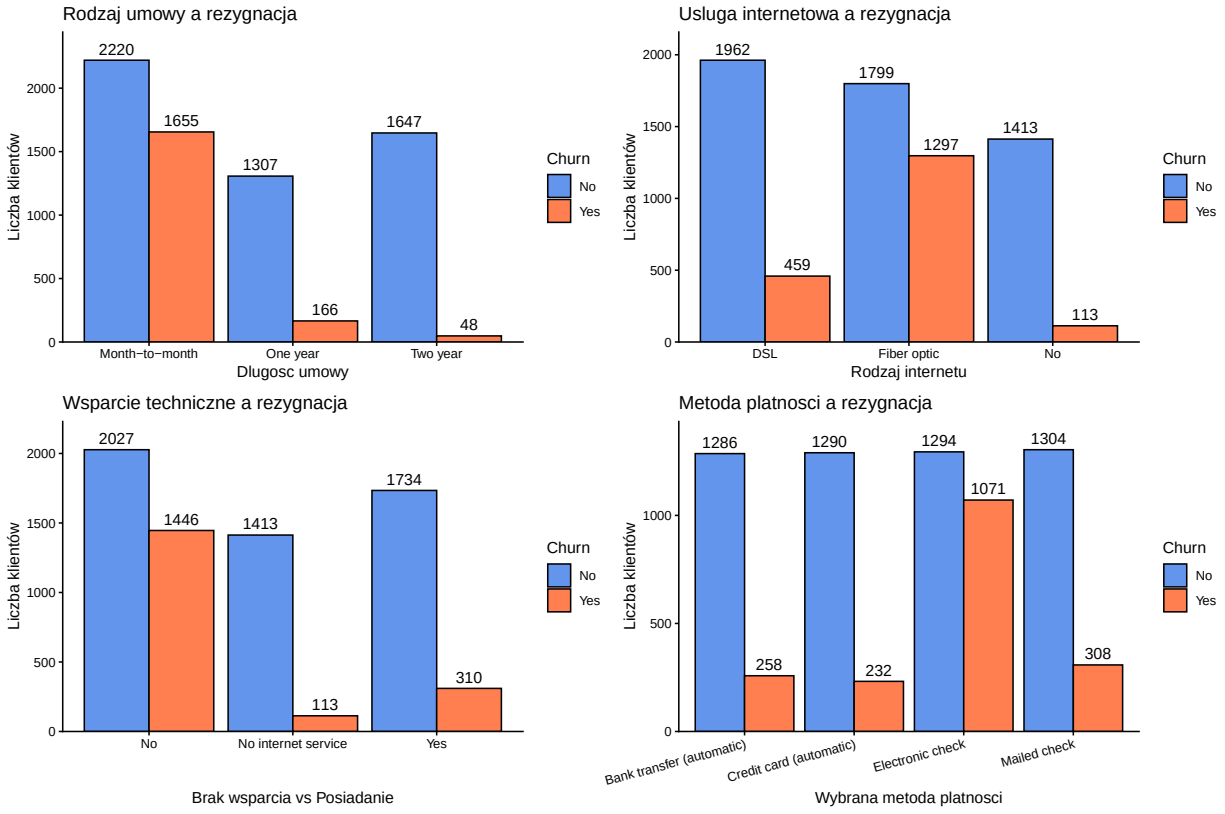

Rysunek 5: Zestawienie wybranych zmiennych jakościowych w podziale na Churn.

5.2 Cechy najlepiej różnicujące klientów

1. Zmienne ilościowe:

- **Staż klienta (`tenure`):** Klienci rezygnujący (Churn = "Yes") mają bardzo mocno skupiony rozkład przy małych wartościach (mediana to zaledwie kilka miesięcy), co oznacza, że rezygnują bardzo szybko po podpisaniu umowy. Klienci lojalni to w dużej mierze osoby o długim stażu (mediana to kilkadziesiąt miesięcy).
- **Miesięczne opłaty (`MonthlyCharges`):** Klienci płacący więcej miesięcznie (mediana rzędu blisko 80) częściej rezygnują z usług w porównaniu do grupy pozostającej, gdzie rozkład opłat jest szerszy, a mediana niższa (ok. 65).

2. Zmienne jakościowe:

- **Rodzaj umowy (`Contract`):** Ogromna większość klientów, którzy zrezygnowali, posiadała umowę odnawianą co miesiąc ("Month-to-month"). Odsetek rezygnacji wśród klientów z umowami na rok lub dwa lata ("One year", "Two year") jest bardzo mały.
- **Typ internetu (`InternetService`):** Klienci posiadający światłowód ("Fiber optic") decydują się na odejście częściej niż użytkownicy łącza "DSL" lub osoby w ogóle niekorzystające z internetu.
- **Usługi wsparcia i bezpieczeństwa (`TechSupport`, `OnlineSecurity`):** Z wykresów wynika, że brak dodatkowego wsparcia technicznego jest powiązany z wyższym wskaźnikiem rezygnacji.
- **Metoda płatności (`PaymentMethod`):** Klienci opłacający rachunki za pomocą elektronicznego czeku ("Electronic check") rezygnują drastycznie częściej niż osoby korzystające z innych metod, np. kart kredytowych czy przelewów bankowych.

6 Etap 4. Podsumowanie – wnioski z przeprowadzonej analizy

6.1 Krótkie podsumowanie wyników z etapów 1–3

W trakcie analizy przeszliśmy przez trzy główne kroki:

1. **Etap 1 (Przygotowanie danych):** Zbiór danych był całkiem uporządkowany. Wymagał jedynie drobnych poprawek, takich jak usunięcie niepotrzebnego ID klienta oraz wstawienie zer w opłatach u zupełnie nowych klientów.
2. **Etap 2 (Analiza opisowa):** Wykresy pokazały nam ogólny obraz sytuacji. Zauważyliśmy m.in., że większość klientów (około 73%) zostaje w firmie, a 27% decyduje się na odejście.
3. **Etap 3 (Analiza opisowa z podziałem na grupy):** Dzieląc klientów na tych, którzy odeszli i tych, którzy zostali, odkryliśmy, że rezygnacja z usług nie jest przypadkowa. Bardzo mocno zależy ona od takich rzeczy jak rodzaj umowy czy staż klienta.

6.2 Profil typowego klienta firmy

Na podstawie danych dowiedzieliśmy następujących faktór o klientach:

- **Kim są?** Klienci dzielą się mniej więcej po równo na kobiety i mężczyzn. Większość z nich nie ma nikogo na utrzymaniu i nie zalicza się do grupy seniorów.
- **Czego używają?** Prawie wszyscy mają telefon, a w przypadku internetu najchętniej wybierają światłowód. Dodatkowe usługi, jak telewizja czy filmy na żądanie, interesują około połowę z nich.
- **Jakie mają umowy?** Klienci bardzo cenią sobie elastyczność – zdecydowanie najczęściej wybierają umowę odnawianą z miesiąca na miesiąc i płacą za pomocą elektronicznego czeku.

6.3 Przyczyny odchodzenia (Churn) i co firma może z tym zrobić

6.3.1 Dlaczego klienci odchodzą?

Analiza wykazała, że klienci, którzy rezygnują z usług firmy, mają wspólne cechy:

1. **Odchodzą bardzo szybko:** Najwięcej rezygnacji pojawia się w pierwszych miesiącach po podpisaniu umowy.
2. **Mają krótkie umowy:** Odchodzą głównie osoby z umowami "z miesiąca na miesiąc", ponieważ mogą to zrobić w każdej chwili bez konsekwencji.
3. **Mają światłowód:** O dziwo, klienci korzystający ze światłowodu rezygnują częściej niż reszta. Może to oznaczać, że usługa ta jest za droga albo sprawia problemy techniczne.
4. **Nie mają wsparcia technicznego:** Osoby, które nie wykupiły dodatkowego wsparcia technicznego, częściej rezygnują z usług.

6.3.2 Co firma powinna zrobić?

Aby zatrzymać klientów, firma mogłaby wprowadzić kilka zmian:

1. **Zachęcać do dłuższych umów:** Skoro umowy miesięczne to główny powód ucieczek, warto kusić klientów zniżkami za podpisanie umowy na rok lub dwa lata.
2. **Zaopiekować się nowymi klientami:** Skoro klienci odchodzą na samym początku, firma powinna w pierwszych miesiącach częściej sprawdzać, czy wszystko u nich działa i czy są zadowoleni.
3. **Sprawdzić światłowody:** Należy sprawdzić, dlaczego ta usługa traci klientów – być może trzeba poprawić jej jakość lub obniżyć cenę.